

Распределение Уэлча

Аверьянов, Григорян, Романенко

НИУ "Высшая школа экономики"



Определение

t-критерий Уэлча — тест, основанный на распределении Стьюдента и предназначенный для проверки статистической гипотезы о равенстве математических ожиданий случайных величин, имеющих необязательно равные известные дисперсии. Является модификацией t-критерия Стьюдента. Назван в честь британского статистика Бернарда Льюиса Уэлча.

Предпосылки

Для применения двухвыборочного **t-критерия Стьюдента** необходимо, чтобы две независимые выборки имели нормальное распределение и истинные дисперсии были равны. В случае **t-критерия Уэлча** дисперсии уже могут быть не равны, но должны быть известны. Предпосылка о нормальном распределении данных сохраняется.

Вычисление статистики

Пусть даны две независимые выборки нормально распределённых случайных величин:

$$X_1, \dots, X_{n_x} \sim \mathcal{N}(\mu_x, \sigma_x^2)$$

$$Y_1, \dots, Y_{n_y} \sim \mathcal{N}(\mu_y, \sigma_y^2)$$

Проверяем следующую нулевую гипотезу о равенстве математический ожиданий:

$$H_0 : \mu_x = \mu_y$$

Пусть нулевая гипотеза верна. Тогда $E(\bar{X} - \bar{Y}) = 0$ и $Var(\bar{X} - \bar{Y}) = \frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}$. Пусть $\hat{\sigma}_x^2 = \sum_{i=1}^{n_x} \frac{(X_i - \bar{X})^2}{n_x - 1}$ и

$\hat{\sigma}_y^2 = \sum_{i=1}^{n_y} \frac{(Y_i - \bar{Y})^2}{n_y - 1}$ - несмещенные оценки дисперсий $\sigma_x^2 \sigma_y^2$ соответственно.

Рассчитаем следующую статистику:

$$t = \frac{\bar{X} - \bar{Y}}{\sqrt{\widehat{Var}(\bar{X} - \bar{Y})}} = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\hat{\sigma}_x^2}{n_x} + \frac{\hat{\sigma}_y^2}{n_y}}} = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}} * \frac{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}}{\sqrt{\frac{\hat{\sigma}_x^2}{n_x} + \frac{\hat{\sigma}_y^2}{n_y}}}$$

Распределение первой статистики является стандартным нормальным распределением:

$$\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}} \sim \mathcal{N}(0, 1)$$

Рассмотрим вторую статистику и для дальнейших вычислений назовем её S :

$$S = \frac{\sigma_x^2/n_x + \sigma_y^2/n_y}{\hat{\sigma}_x^2/n_x + \hat{\sigma}_y^2/n_y}$$

Статистика S напоминает случайную величину с распределением χ^2 , поделенную на степень свободы, но таковой не является. Пусть $Z \sim \chi_d^2$ является случайной величиной с распределением хи-квадрат с d степенями свободы. Мы хотим чтобы S была максимально похожа на $\frac{Z}{d} \sim \frac{\chi_d^2}{d}$, тогда приравняем дисперсии данных случайных величин и выразим d :

$$d = \frac{\left(\sigma_x^2 n_x + \frac{\sigma_y^2}{n_y}\right)^2}{\frac{\sigma_x^4}{n_x^2(n_x - 1)} + \frac{\sigma_y^4}{n_y^2(n_y - 1)}}$$

Итог

В конечном итоге имеем при справедливости нулевой гипотезы:

$$t \stackrel{approx.}{\sim} t_d$$

где d находится как:

$$d = \left\lfloor \frac{\left(\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}\right)^2}{\frac{\sigma_x^4}{n_x^2(n_x - 1)} + \frac{\sigma_y^4}{n_y^2(n_y - 1)}} \right\rfloor$$

При достаточно больших объемах выборок мы можем воспользоваться нормальной аппроксимацией:

$$t = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\hat{\sigma}_x^2}{n_x} + \frac{\hat{\sigma}_y^2}{n_y}}} \xrightarrow{n_x, n_y \rightarrow \infty} \mathcal{N}(0, 1)$$

Программная реализация

Язык

Python

R

MATLAB

Excel 2010-

Excel 2010+

Google Sheets

Код

```
scipy.stats.ttest_ind(a, b, equal_var=False)
t.test(data1, data2, alternative="two.sided var.equal=FALSE)
ttest2(data1, data2, 'Vartype', 'unequal')
TTEST(array1, array2, tails, type)
T.TEST(array1, array2, tails, type)
TTEST(range1, range2, tails, type)
```




Рис. 1: Relation between p-value and number of tests.

Замечания по использованию

t-критерий Уэлча не имеет преимуществ относительно t-критерия Стьюдента в том случае, если дисперсии независимых выборок равны. В связи с этим можно подумать, что эффективным способом проведения анализа будет выполнение первоначального теста на равенство дисперсий, а затем выполнение t-критерия Стьюдента, если дисперсии равны, или t-критерия с Уэлча, если они не совпадают. Проблема такого подхода состоит в том, что сочетание этого предварительного теста и одного из t-критериев, менее эффективно контролирует частоту ошибок I рода, нежели выполнение t-теста Уэлча вне зависимости от данных дисперсий.